Methodische Untersuchung von Deep-Learning-Modellen für die Klassifizierung zeitlicher Signale

Projekt: Deep Learning in Audio Processing

Jamil Osoria Peralta

16. März 2026

Akustische Szenenklassifizierung

- Problemstellung:
  Es sei C ein Audio-Clip fester Länge. Gebe zum Audio-Clip C ein Label ℓ_C aus einer festen Menge von Labels L aus, das die Umgebung des Ursprungs von C benennt.
- Diese Problemstellung ist die erste Aufgabenstellung der jährlich durchgeführten DCASE-Challenge [1].
- In der DCASE-Challenge aus dem Jahr 2017 stammen die mitgelieferten Audio-Clips jeweils aus einer von 15 Umgebungen.

Datensatz

- Der mitgelieferte Datensatz bestand aus 4680 Trainings-Clips und 560 Validierungs-Clips, jeweils à 10 Sekunden.
- Gesamte Datenmenge: 14,5 Stunden an Audiomaterial, aufgezeichnet mit einer Abtastrate von 44 100 Hz und im Stereo-Format.
- Audio-Clips werden mittels Short-Time Fourier Transform (STFT) in log-mel Spektrogramme überführt: $\mathcal{X} \in \mathbb{R}^{F \times T}$
  - F: Anzahl der Frequenzbins
  - T: Anzahl der Zeit-Frames

  ist also der Eingaberaum

Pipeline

Wir benutzen

$$C \xrightarrow{\Phi} \mathcal{X} \in \mathbb{R}^{F\times T} \xrightarrow{\Psi_k} \tilde{\mathcal{X}} \in \mathbb{R}^{F\times k\times \dots} \xrightarrow{f_\theta} [0,1]^{|L|}$$

als Pipeline mit

- Φ: Merkmals-Extraktion (STFT + log-mel)
- Ψ_k: Kontextfenster / Kanal-Stapelung
- f_θ: Modell
- und wollen: jeden i-ten Eintrag aus $[0,1]^{|L|}$ als geschätze Wahrscheinlichkeit $\hat{\Pr}[\ell_i \mid C]$.

Die Aufgabe ist also, ein Modell f_θ mit Parametern θ zu finden, das den Klassifikationsfehler minimiert:

$$\begin{aligned} &\min_\theta \mathcal{L}(\ell, f_\theta(\tilde{\mathcal{X}})) \\ = &\min_\theta \left[-\sum_{i=1}^{|L|} \ell_i \log f_\theta(\tilde{\mathcal{X}})_i \right], \text{mit } f_\theta \in \mathcal{H} \end{aligned}$$

- Die Wahl von $\mathcal{H}$ ist die zentrale Designentscheidung.

Architekturen

- Fragestellung: wie verändert sich das Ergebnis mit einem zunehmend an dem Problem ausgerichteten induktiven Bias?
- Explorativ: schrittweise Anpassung des induktiven Bias.

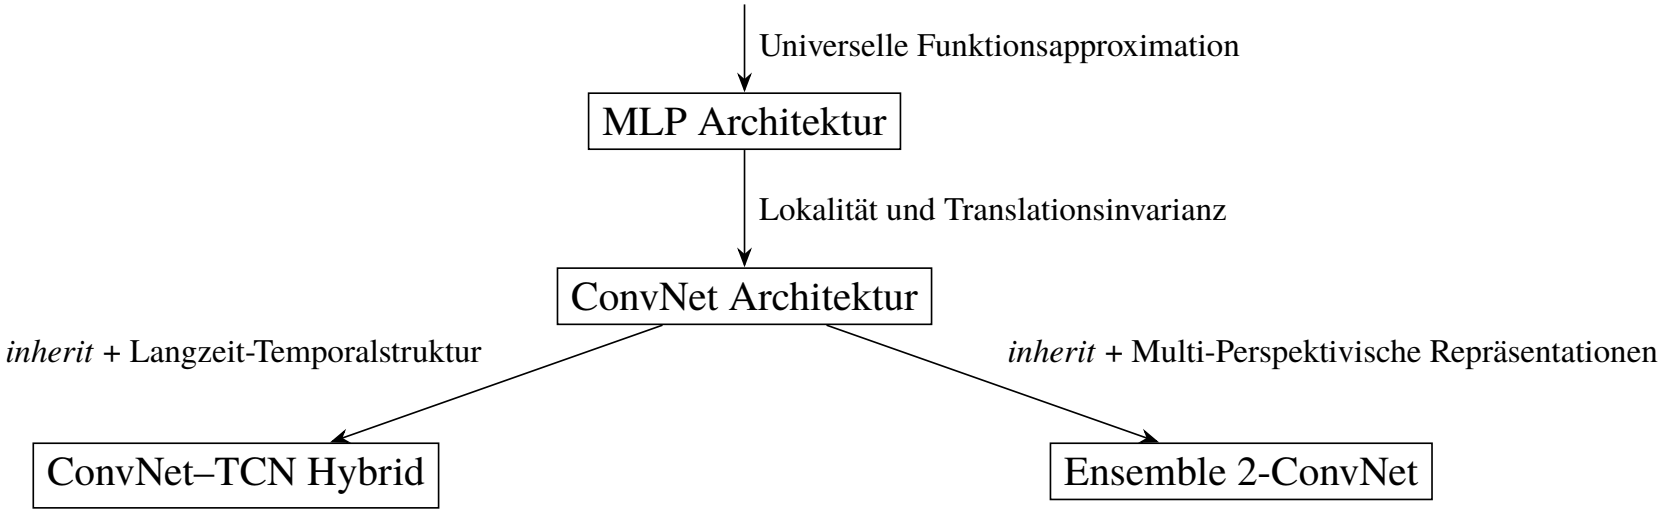

Architekturen

- Fragestellung: wie verändert sich das Ergebnis mit einem zunehmend an dem Problem ausgerichteten induktiven Bias?
- Explorativ: schrittweise Anpassung des induktiven Bias.

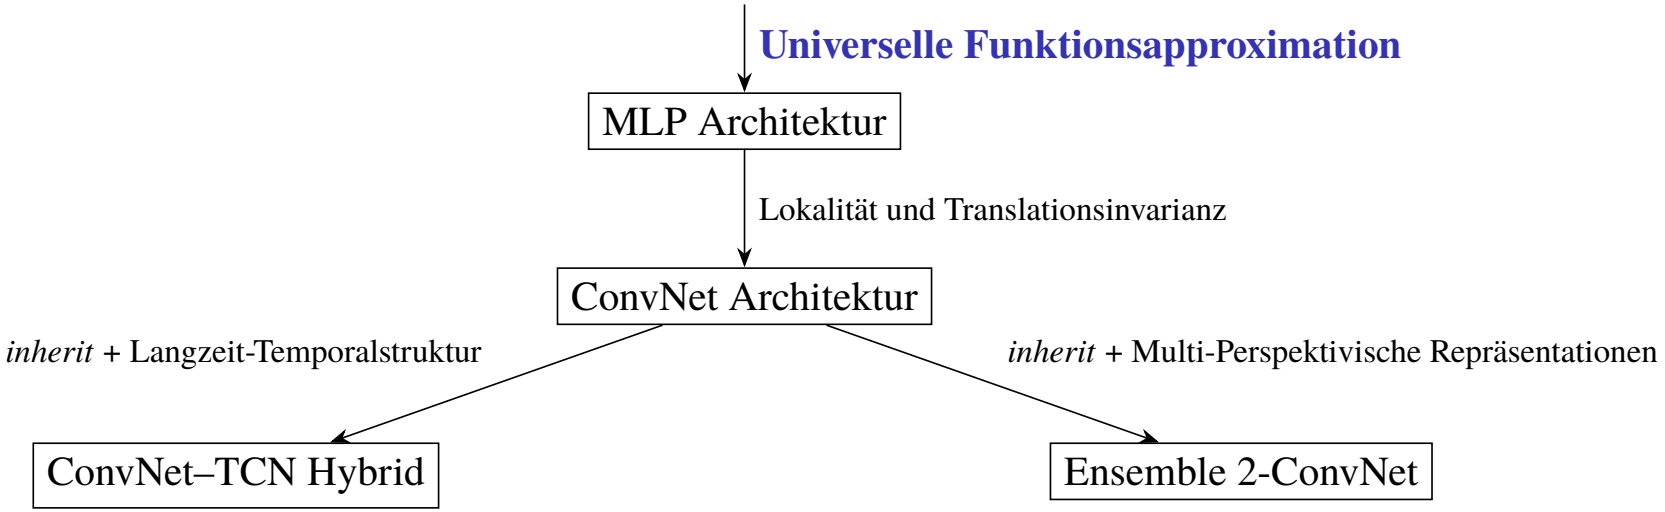

Universelle Funktionsapproximation

- Baseline: universeller Funktionsapproximator (MLP)

$$f_\theta : \mathbb{R}^{F \cdot k} \to [0,1]^{|L|}$$

und Schlussfolgerung über

$$\hat{\ell} = \arg\max_{\ell \in L} f_\theta(\cdot)_\ell$$

- Keine explizite Annahme über Struktur der Eingabe $=: \mathcal{H}_{\text{MLP}}$
- Korrelationen müssen aus den Daten gelernt werden
- Frame-basierte Verarbeitung mit Kontextfenster
- Stapelung k aufeinanderfolgender Frames:

$$\Psi_k(x) = \begin{bmatrix} x_{:,t-k+1} \\ \vdots \\ x_{:,t} \end{bmatrix} \in \mathbb{R}^{F \cdot k} \text{ mit } x \in \mathcal{X}$$

- Zeitliche Struktur wird implizit als Vektor enkodiert

Log-mel Spektrogramm

Feature Extraktion Φ liegt in bildartiger Form vor:

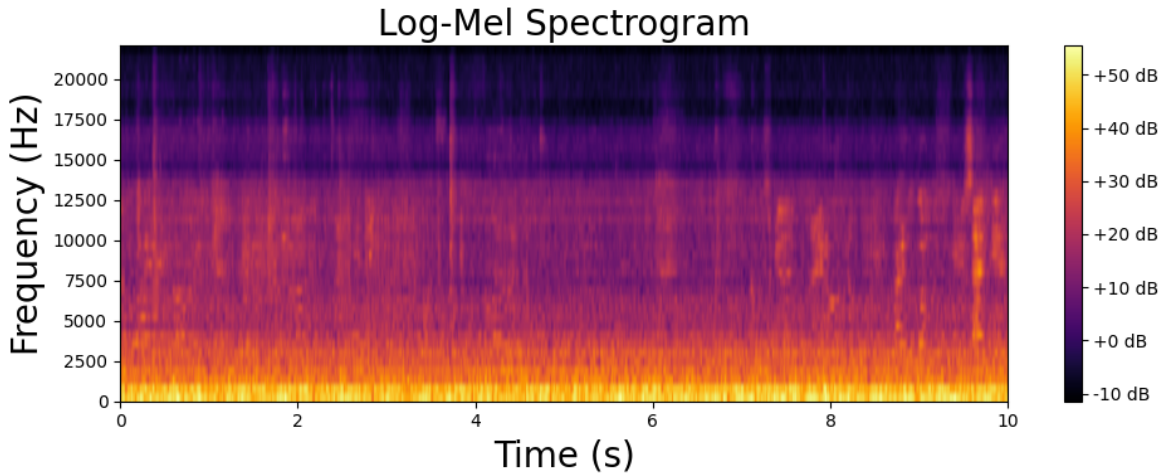

darüber können wir Kontextfenster Ψ_k definieren:

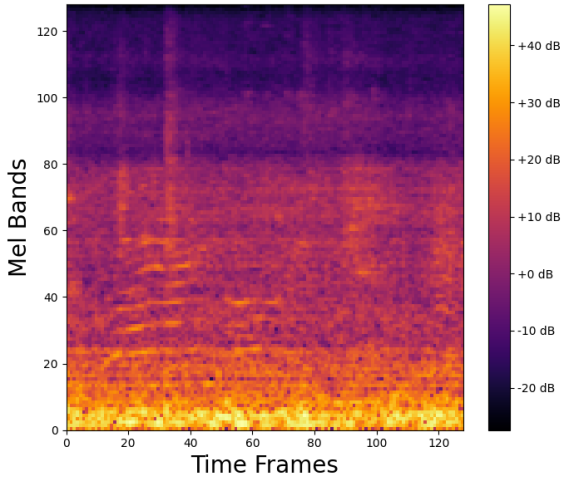

und ein Modell f_θ konstruieren, dass diese Bildstruktur ausnutzt.

Architekturen

- Fragestellung: wie verändert sich das Ergebnis mit einem zunehmend an dem Problem ausgerichteten induktiven Bias?
- Explorativ: schrittweise Anpassung des induktiven Bias.

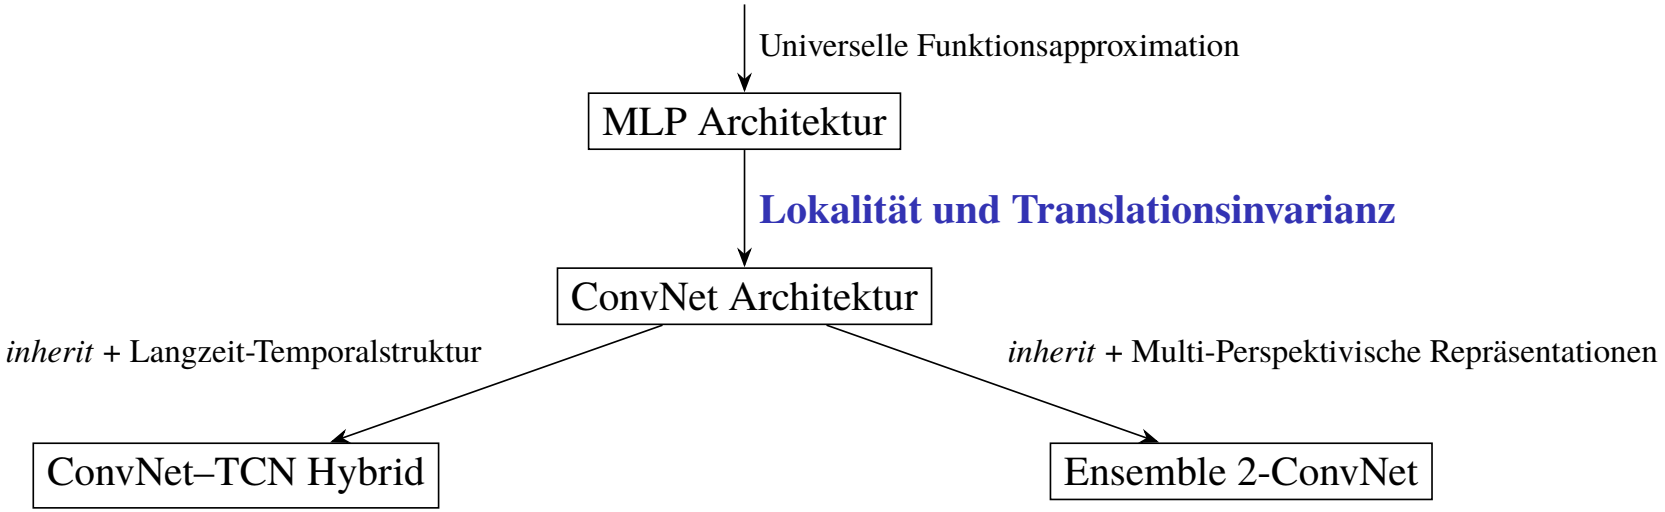

Lokalität und Translationsinvarianz

- 2D-Faltung über Zeit–Frequenz-Kontextfenster des log-mel Spektrogramms mit

$$\Psi_k(\mathcal{X}) = \{\mathcal{X}_{:,t:t+k-1}\}_t$$

- Annahme lokaler, hierarchischer Korrelationen in Zeit und Frequenz $=: \mathcal{H}_{\text{ConvNet}}$
- Gewichtsteilung induziert Translationsinvarianz [2]
- Expliziter struktureller Bias gegenüber MLP
- Modell inspiriert durch VGGNet-Modelle zur Bilderkennung [3]

Lokalität und Translationsinvarianz

VGGNet inspirierte ConvNet Architektur:

Layer	**Out Ch.**	**Kernel / Pool / Notes**
Input: $(128 \times T)$ spec	1	Log-mel spectrogram
Block 1	32	
BatchNorm + LeakyReLU		Pre-activation
Conv 3×3		zero-padding=1
BatchNorm + LeakyReLU		Pre-activation
Conv 3×3		zero-padding=1
MaxPool 2×2		Downsampling
Block 2	64	
Block 3	128	
Block 4	256	
Global AvgPool	256	AdaptiveAvgPool2d(1)
Dense (LeakyReLU, Dropout, 512)		Classifier hidden layer
Dense (Softmax, 15)		Scene classes

Architekturen

- Fragestellung: wie verändert sich das Ergebnis mit einem zunehmend an dem Problem ausgerichteten induktiven Bias?
- Explorativ: schrittweise Anpassung des induktiven Bias.

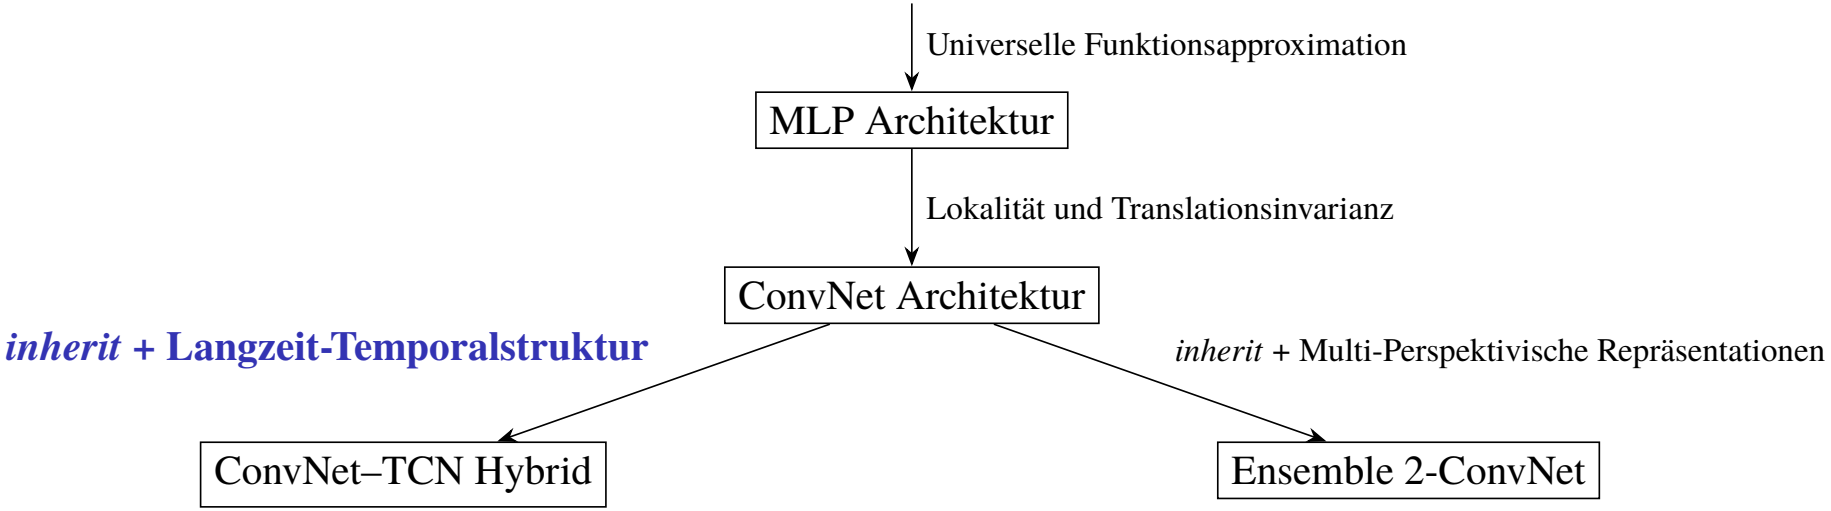

Erweiterung um Langzeit-Temporalstruktur

- ConvNet erfasst primär lokale zeitliche Zusammenhänge
- Erweiterung durch Temporal Convolutional Network (TCN)
- 1D-Faltungen über die Zeitachse mit vergrößertem Rezeptivfeld

$$R = 1 + \sum_{l=1}^{D} (k-1)\, d_l \quad (D\colon \text{ Anzahl der TCN-Layer})$$

- Dilation ermöglicht Modellierung von Langzeitabhängigkeiten $=: \mathcal{H}_{\text{ConvNet–TCN}}$ durch

$$(x *_d w)_t = \sum_{i=0}^{k-1} w^{(i)}\, x_{t-i\cdot d}$$

- Kombination:
  - ▷ ConvNet: lokale Zeit-Frequenz-Muster [2]
  - ▷ TCN: globale zeitliche Dynamik [4]
- Zusätzlicher induktiver Bias für zeitliche Struktur

Erweiterung um Langzeit-Temporalstruktur

Layer	**Out Ch.**	**Notes**
Input: $(128 \times T)$ spec	1	Log-mel spectrogram
Conv. Block 1	32	
Conv. Block 2	64	
TCN Block 1	64	
Dilated Conv1D		$k = 3, d = 1$ padding=same
BatchNorm + LeakyReLU		
Dropout		
Dilated Conv1D		$k = 3, d = 1$
Residual connection		1×1 conv if needed
TCN Block 2	64	$d = 2$
Global AvgPool (time)	64	AdaptiveAvgPool1d(1)
Dense (LeakyReLU, Dropout, 256)		Classifier hidden layer
Dense (Softmax, 15)		Scene classes

Architekturen

- Fragestellung: wie verändert sich das Ergebnis mit einem zunehmend an dem Problem ausgerichteten induktiven Bias?
- Explorativ: schrittweise Anpassung des induktiven Bias.

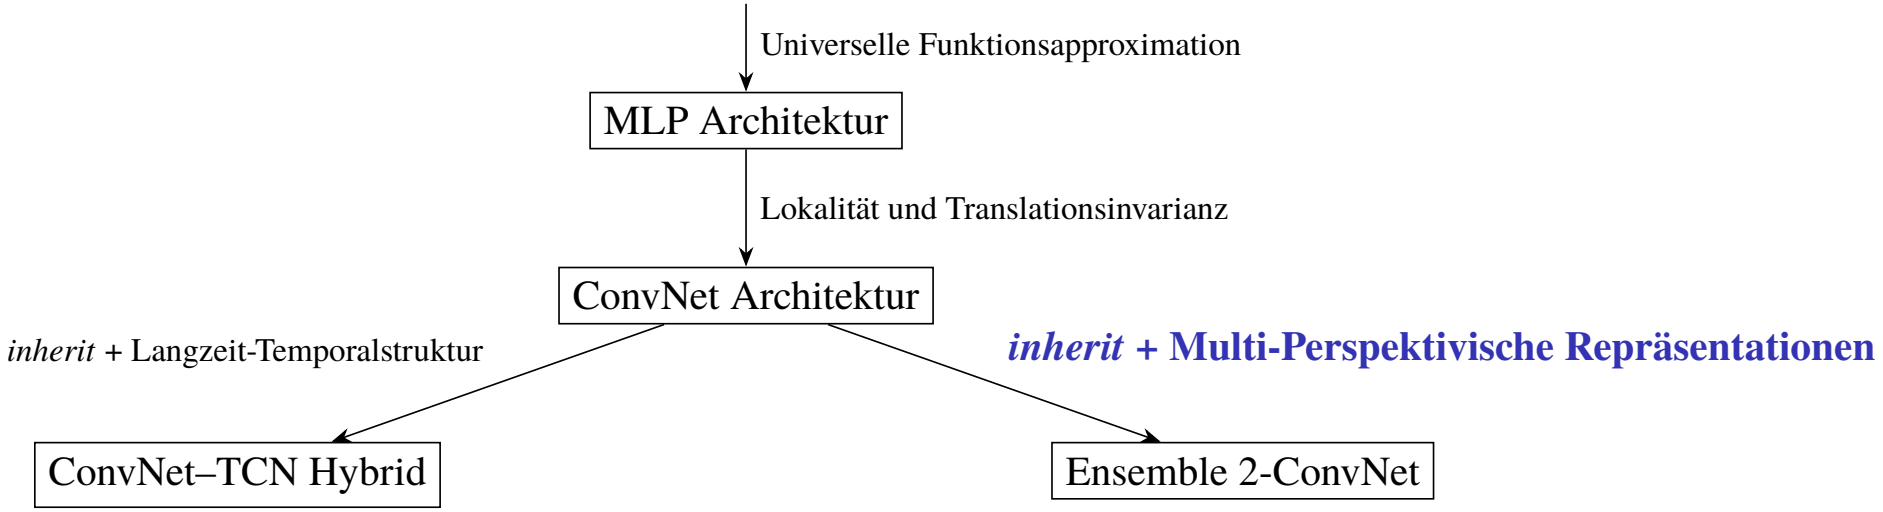

Multi-Perspektivische Repräsentationen

- Mehrere ConvNet-Modelle mit unterschiedlichen Eingaberepräsentationen
- Jede Repräsentation betont unterschiedliche akustische Eigenschaften
- Verwendete Beispiele:
  - Links ($\mathcal{X}^{(L)}$) vs. Rechts ($\mathcal{X}^{(R)}$), s. d. $\mathcal{X} = [\mathcal{X}^{(L)}, \mathcal{X}^{(R)}]$
  - Mitten vs. Seiten

$$\mathcal{X}^{(M)} = \frac{\mathcal{X}^{(L)} + \mathcal{X}^{(R)}}{2}, \ \mathcal{X}^{(S)} = \frac{\mathcal{X}^{(L)} - \mathcal{X}^{(R)}}{2},$$
$$\text{s. d. } \mathcal{X} = \mathcal{X}^{(M)} + \mathcal{X}^{(S)}$$

  - Harmonische vs. perkussive Komponenten

$$\mathcal{X}^{(h)} = \text{Harmonic}(\mathcal{X}), \ \mathcal{X}^{(p)} = \text{Percussive}(\mathcal{X}),$$
$$\text{s. d. } \mathcal{X} = \mathcal{X}^{(h)} + \mathcal{X}^{(p)}$$

- Kombination der Modellvorhersagen (Ensemble Learning) über doppel-zweigige ConvNets (2-ConvNets) [5]
- Induktiver Bias durch ungewichtete Diversität der Repräsentationen

$$f_{\text{ens}}(C) = \text{Agg}\big(f_{\theta_1}(\Psi_{k,1}(\Phi_1(C))), \ldots, f_{\theta_n}(\Psi_{k,n}(\Phi_n(C)))\big)$$

Erweiterung um Multi-Perspektivische Repräsentation

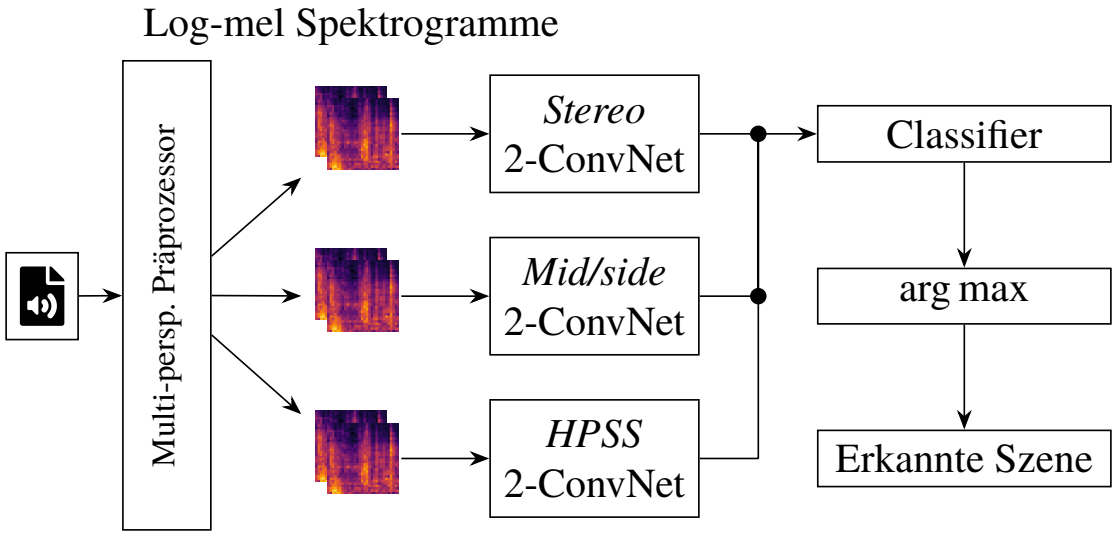

mit 2-ConvNet wie folgt:

Amplituden-normalisierte Audioeingabe	
Channel 1	Channel 2
VGGNet-insp. ConvNet	VGGNet-insp. ConvNet
Konkatenation	
Dense (LeakyReLU, 512)	
Dense (Softmax, 15)	

und

$$\hat{\ell} = \arg\max_{\ell \in L} \sum_{m=1}^{M} \alpha_m f_{\theta_m}(\Psi_{k,m}(\Phi_m(C)))_\ell, \alpha_m = 1/M$$

Resultate—Vergleich mit Han et al. (2017)

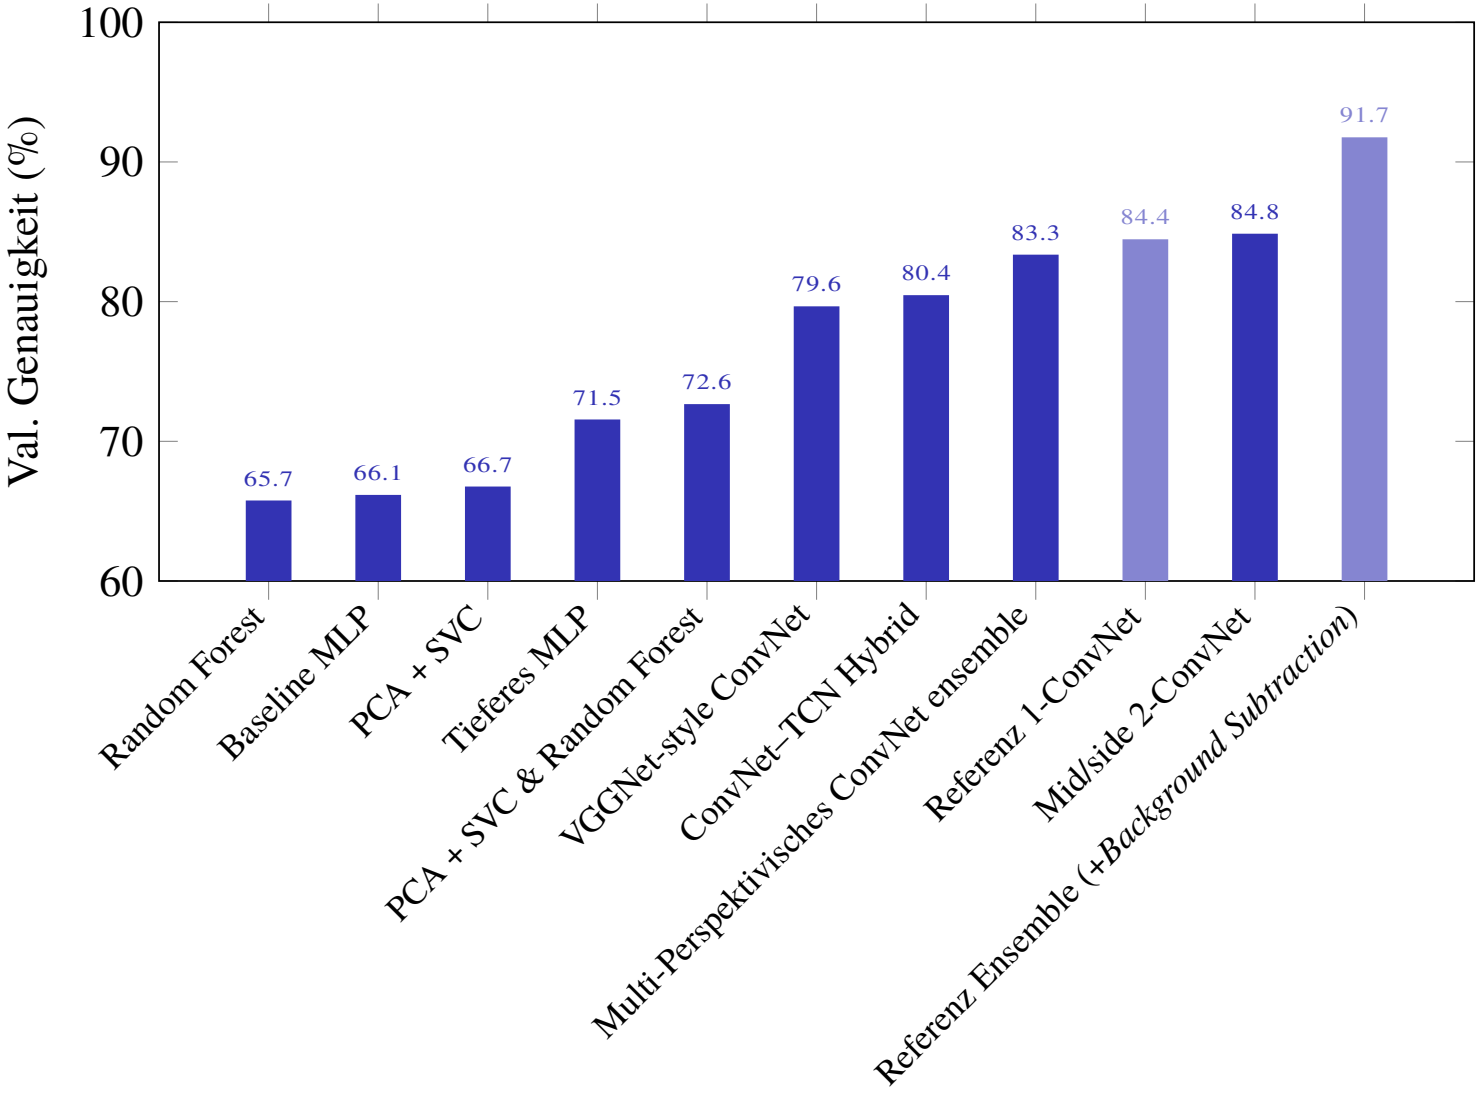

Take-Aways

- Explizite Annahmen über Datenstruktur führten zu besserer Generalisierung:

$$\mathcal{H}_{\text{ConvNet–TCN}} \subset \mathcal{H}_{\text{ConvNet}} \subset \mathcal{H}_{\text{MLP}} \subseteq \mathcal{F}$$

- Die Leistungen vorgestellter Modelle waren also maßgeblich durch den induktiven Bias bestimmt
- Strukturierte Repräsentationen haben das Lernproblem vereinfacht
- Modellarchitekturen als zunehmend eingeschränkte Hypothesenräume durch explizite Annahmen über Zeit- und Frequenzstruktur ein engerer, aber besser generalisierender Teilraum der universellen Funktionsklasse
- Modellarchitekturen entsprachen grob Hypothesen über den Datenraum

[1] T. Heittola, *Acoustic scene classification - DCASE*, en.

[2] Y. Han und K. Lee, *Acoustic scene classification using convolutional neural network and multiple-width frequency-delta data augmentation*, 2016.

[3] K. Simonyan und A. Zisserman, *Very Deep Convolutional Networks for Large-Scale Image Recognition*, 2015.

[4] K. Guirguis, C. Schorn, A. Guntoro, S. Abdulatif und B. Yang, „SELD-TCN: Sound Event Localization & Detection via Temporal Convolutional Networks," in *2020 28th European Signal Processing Conference (EUSIPCO)*, IEEE, Jan. 2021, S. 16–20. DOI: 10.23919/eusipco47968.2020.9287716.

[5] Y. Han, K. Lee und J. Park, „Convolutional Neural Networks with Binaural Representations and Background Subtraction for Acoustic Scene Classification," DCASE2017 Challenge, Techn. Ber., Sep. 2017.